

Lý thuyết: BG-NBD & Gamma-Gamma → Predictive CLV

Mục lục

1. Giới thiệu mô hình dự báo CLV (Predictive Lifetime Value)

- 1.1. CLV là gì?
- 1.2. Tại sao cần Predictive CLV?
- 1.3. Công thức CLV cơ bản
- 1.4. Phương pháp tính CLV

2. BG-NBD Model

- 2.1. Tổng quan
- 2.2. Logic "Alive/Dead" Customer
- 2.3. Giả định và công thức của BG-NBD
- 2.4. Tham số của BG-NBD
- 2.5. Input của BG-NBD
- 2.6. Output của BG-NBD
- 2.7. Công thức BG-NBD
- 2.8. Ví dụ minh họa: Tại sao cần cả NBD và BG?
- 2.9. Ước lượng tham số

3. Gamma-Gamma Model

- 3.1. Tổng quan
- 3.2. Giả định
- 3.3. Input của Gamma-Gamma
- 3.4. Output của Gamma-Gamma
- 3.5. Công thức Gamma-Gamma
- 3.6. Ước lượng tham số

4. Kết hợp BG-NBD và Gamma-Gamma để tính CLV

- 4.1. Công thức CLV
- 4.2. CLV trong khoảng thời gian t
- 4.3. CLV với discount rate
- 4.4. Quy trình tính CLV

5. Ứng dụng CLV trong Cross-sell, Up-sell, Ưu tiên khách hàng

- 5.1. Cross-sell
- 5.2. Up-sell
- 5.3. Ưu tiên khách hàng
- 5.4. Tối ưu ngân sách marketing
- 5.5. Customer Acquisition Cost (CAC) vs CLV

6. Ưu và nhược điểm của BG-NBD + Gamma-Gamma

- 6.1. Ưu điểm
- 6.2. Nhược điểm

7. Best Practices

8. Thư viện Python

1. Giới thiệu mô hình dự báo CLV (Predictive Lifetime Value)

1.1. CLV là gì?

Customer Lifetime Value (CLV) là tổng giá trị dự kiến mà một khách hàng sẽ mang lại cho doanh nghiệp trong suốt mối quan hệ với họ.

1.2. Tại sao cần Predictive CLV?

1.2.1. Hạn chế của Historical Value

- Chỉ phản ánh quá khứ, không dự đoán tương lai
- Không tính đến khả năng churn
- Không ước lượng được số giao dịch và giá trị tương lai

1.2.2. Lợi ích của Predictive CLV

- **Dự đoán tương lai:** Biết được giá trị khách hàng sẽ mang lại
- **Tối ưu ngân sách:** Đầu tư vào khách hàng có CLV cao
- **Cá nhân hóa:** Chiến lược phù hợp với từng khách hàng
- **ROI tính toán:** So sánh chi phí acquisition với CLV

1.3. Công thức CLV cơ bản

Công thức đơn giản:

$$CLV = \text{Average Transaction Value} \times \text{Number of Transactions} \times \text{Customer Lifespan}$$

Công thức với discount rate:

$$CLV = \sum_{t=1}^T \frac{\text{Revenue}_t}{(1 + r)^t}$$

Trong đó:

- Revenue_t : Doanh thu tại thời điểm t
- r : Discount rate (tỷ lệ chiết khấu)
- t : Thời gian (tháng/năm)
- T : Thời gian tổng cộng

1.4. Phương pháp tính CLV

1. **Historical CLV**: Dựa trên dữ liệu quá khứ
2. **Predictive CLV**: Sử dụng mô hình thống kê/machine learning
 - BG-NBD + Gamma-Gamma (probabilistic)
 - Machine Learning (regression, neural networks)

2. BG-NBD Model

2.1. Tổng quan

BG-NBD (Beta Geometric / Negative Binomial Distribution) là mô hình probabilistic để dự đoán số giao dịch tương lai của khách hàng.

BG-NBD = NBD (Negative Binomial Distribution) + BG (Beta Geometric)

Mô hình này kết hợp **2 thành phần chính** để giải quyết 2 vấn đề riêng biệt:

1. **NBD (Negative Binomial Distribution)**: Mô hình hóa **số giao dịch** khi khách hàng còn "alive"
2. **BG (Beta Geometric)**: Mô hình hóa **quá trình churn** (khách hàng trở thành "dead")

2.1.1. Tại sao cần cả 2 thành phần?

Vấn đề thực tế:

Khi quan sát dữ liệu giao dịch, chúng ta thấy:

- Một số khách hàng giao dịch thường xuyên (frequency cao)
- Một số khách hàng giao dịch ít (frequency thấp)
- Một số khách hàng đã lâu không giao dịch

Câu hỏi quan trọng: Khách hàng không giao dịch là do:

- **Lý do 1:** Họ có tần suất giao dịch thấp (λ thấp) nhưng vẫn còn "alive" → Sẽ giao dịch trong tương lai
- **Lý do 2:** Họ đã churn (trở thành "dead") → Sẽ không bao giờ giao dịch nữa

→ Cần phân biệt được 2 trường hợp này!

Giải pháp: Kết hợp NBD + BG

NBD (Negative Binomial Distribution) - Mô hình số giao dịch:

- **Mục đích:** Mô hình hóa sự khác biệt về **tần suất giao dịch** giữa các khách hàng
- **Giả định:** Khách hàng còn "alive" sẽ giao dịch theo quá trình Poisson với rate λ
- λ khác nhau giữa các khách hàng → Mô hình bằng Gamma distribution
- **Kết quả:** Phân phối số giao dịch khi khách hàng còn "alive" là **Negative Binomial**

BG (Beta Geometric) - Mô hình quá trình churn:

- **Mục đích:** Mô hình hóa **thời điểm churn** của khách hàng
- **Giả định:** Sau mỗi giao dịch, khách hàng có xác suất p để churn
- p khác nhau giữa các khách hàng → Mô hình bằng Beta distribution

- **Kết quả:** Số giao dịch trước khi churn tuân theo **Geometric distribution** với p từ Beta

Tại sao không thể dùng riêng lẻ?

Nếu chỉ dùng NBD:

- ✗ Giả định tất cả khách hàng đều còn "alive"
- ✗ Không thể phân biệt khách hàng "alive nhưng ít giao dịch" vs "đã churn"
- ✗ Dự đoán sẽ sai cho khách hàng đã churn (sẽ dự đoán họ vẫn giao dịch)

Nếu chỉ dùng BG:

- ✗ Chỉ mô hình được quá trình churn, không mô hình được tần suất giao dịch
- ✗ Không thể dự đoán số giao dịch tương lai (chỉ biết khi nào churn)
- ✗ Bỏ qua sự khác biệt về hành vi giao dịch giữa các khách hàng

Kết hợp NBD + BG:

- ☒ Mô hình được cả tần suất giao dịch (NBD) và quá trình churn (BG)
- ☒ Phân biệt được khách hàng "alive nhưng ít giao dịch" vs "đã churn"
- ☒ Dự đoán chính xác số giao dịch tương lai, tính cả khả năng churn

2.1.2. Cơ chế hoạt động của BG-NBD

Quá trình mô hình hóa:

1. Khách hàng bắt đầu với:
 - Transaction rate: $\lambda \sim \text{Gamma}(r, \alpha)$ [từ NBD]
 - Churn probability: $p \sim \text{Beta}(a, b)$ [từ BG]
2. Khi khách hàng còn "alive":
 - Giao dịch xảy ra theo Poisson process với rate λ
 - Sau mỗi giao dịch, có xác suất p để churn
3. Nếu churn (trở thành "dead"):
 - Không còn giao dịch nữa
4. Quan sát được:
 - x : Số giao dịch trong quá khứ
 - t_x : Thời gian từ lần đầu đến lần cuối
 - T : Tổng thời gian quan sát
5. Cần ước lượng:
 - $P(\text{alive})$: Xác suất còn "alive" tại thời điểm T
 - $E[\text{transactions}]$: Số giao dịch dự kiến trong tương lai

Visualization minh họa:

```

import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import nbinom, geom

fig, axes = plt.subplots(2, 2, figsize=(14, 10))

# ===== NBD: Negative Binomial Distribution =====
# NBD mô hình số giao dịch khi còn "alive"
# NBD = Gamma-Poisson mixture
n = np.arange(0, 20)
for r, p_nbd in [(2, 0.3), (3, 0.4), (5, 0.5)]:
    # Negative Binomial: số lần thất bại trước khi đạt r lần thành công
    # Ở đây: số giao dịch = r + số lần "không giao dịch"
    axes[0, 0].plot(n, nbinom.pmf(n, r, p_nbd),
                    marker='o', label=f'r={r}, p={p_nbd}', linewidth=2)
axes[0, 0].set_xlabel('Number of Transactions', fontsize=12)
axes[0, 0].set_ylabel('Probability', fontsize=12)
axes[0, 0].set_title('NBD: Distribution of Transactions (when alive)',
                    fontsize=14, fontweight='bold')
axes[0, 0].legend(fontsize=10)
axes[0, 0].grid(True, alpha=0.3)

# ===== BG: Beta Geometric =====
# Geometric distribution mô hình số giao dịch trước khi churn
# p khác nhau → Beta distribution
k = np.arange(1, 20) # Số giao dịch trước khi churn
for p_geom in [0.1, 0.2, 0.3]:
    axes[0, 1].plot(k, geom.pmf(k, p_geom),
                    marker='s', label=f'p={p_geom}', linewidth=2)
axes[0, 1].set_xlabel('Number of Transactions Before Churn', fontsize=12)
axes[0, 1].set_ylabel('Probability', fontsize=12)
axes[0, 1].set_title('Geometric: Transactions Before Churn',
                    fontsize=14, fontweight='bold')
axes[0, 1].legend(fontsize=10)
axes[0, 1].grid(True, alpha=0.3)

# ===== So sánh: Chỉ NBD vs BG-NBD =====
# Scenario: Khách hàng có 0 giao dịch trong 90 ngày
time_points = np.arange(0, 180, 1)

# Chỉ dùng NBD (giả định tất cả đều alive)
lambda_low = 0.01 # Tần suất thấp
prob_alive_nbd_only = np.exp(-lambda_low * time_points) # Xác suất ít nhất 1
giao dịch
expected_trans_nbd = lambda_low * time_points

# BG-NBD (tính cả khả năng churn)
# Giả sử p = 0.3 (30% churn sau mỗi giao dịch)
p_churn = 0.3
# Nếu đã churn → không giao dịch
# Nếu còn alive với λ thấp → ít giao dịch
prob_alive_bgnbd = 0.7 # Giả sử 70% còn alive

```

```

expected_trans_bgnbd = probab_alive_bgnbd * lambda_low * time_points

axes[1, 0].plot(time_points, expected_trans_nbd,
                label='NBD Only (assumes all alive)', linewidth=2, linestyle='--')
axes[1, 0].plot(time_points, expected_trans_bgnbd,
                label='BG-NBD (accounts for churn)', linewidth=2)
axes[1, 0].set_xlabel('Time (days)', fontsize=12)
axes[1, 0].set_ylabel('Expected Transactions', fontsize=12)
axes[1, 0].set_title('Comparison: NBD Only vs BG-NBD',
                    fontsize=14, fontweight='bold')
axes[1, 0].legend(fontsize=10)
axes[1, 0].grid(True, alpha=0.3)

# ===== P(alive) theo thời gian =====
# Khách hàng không giao dịch trong t ngày
t_no_transaction = np.arange(0, 180, 1)

# NBD only: P(alive) = 1 (luôn giả định còn alive)
probab_alive_nbd = np.ones_like(t_no_transaction)

# BG-NBD: P(alive) giảm dần nếu không có giao dịch
# Công thức đơn giản hóa: P(alive) giảm theo thời gian
probab_alive_bgnbd_time = np.exp(-0.02 * t_no_transaction) # Giảm dần

axes[1, 1].plot(t_no_transaction, probab_alive_nbd,
                label='NBD Only (P(alive) = 1)', linewidth=2, linestyle='--')
axes[1, 1].plot(t_no_transaction, probab_alive_bgnbd_time,
                label='BG-NBD (P(alive) decreases)', linewidth=2)
axes[1, 1].set_xlabel('Days Without Transaction', fontsize=12)
axes[1, 1].set_ylabel('P(alive)', fontsize=12)
axes[1, 1].set_title('P(alive) Over Time (No Transactions)',
                    fontsize=14, fontweight='bold')
axes[1, 1].legend(fontsize=10)
axes[1, 1].grid(True, alpha=0.3)
axes[1, 1].set_ylim(0, 1.1)

plt.tight_layout()
plt.savefig('bgnbd_components.png', dpi=300, bbox_inches='tight')
plt.show()

```

Giải thích hình ảnh:

1. NBD (trên trái): Phân phối số giao dịch khi khách hàng còn "alive"

- Mô tả sự khác biệt về tần suất giao dịch
- Khách hàng có λ cao $\rightarrow$ nhiều giao dịch hơn

2. Geometric (trên phải): Phân phối số giao dịch trước khi churn

- Mô tả quá trình churn
- Khách hàng có p cao $\rightarrow$ churn sớm hơn

3. So sánh NBD vs BG-NBD (dưới trái):

- NBD only: Luôn giả định khách hàng còn alive → dự đoán quá cao
- BG-NBD: Tính cả khả năng churn → dự đoán chính xác hơn

4. P(alive) theo thời gian (dưới phải):

- NBD only: $P(\text{alive}) = 1$ (luôn giả định còn alive)
- BG-NBD: $P(\text{alive})$ giảm dần nếu không có giao dịch → realistic hơn

2.2. Logic "Alive/Dead" Customer

2.2.1. Khái niệm

- **Alive:** Khách hàng vẫn đang hoạt động, có khả năng thực hiện giao dịch
- **Dead:** Khách hàng đã churn, không còn thực hiện giao dịch

2.2.2. Vấn đề

- Không thể quan sát trực tiếp trạng thái "alive/dead"
- Khách hàng không giao dịch có thể:
 - Đang "alive" nhưng chưa có nhu cầu
 - Đã "dead" (churn)

2.2.3. Giải pháp

BG-NBD ước lượng xác suất khách hàng còn "alive" dựa trên hành vi quá khứ.

2.3. Giả định và công thức của BG-NBD

2.3.1. Công thức phân phối: Gamma và Beta

[Phần công thức chi tiết được trình bày ở dưới, xem 2.3.1.1 và 2.3.1.2]

2.3.2. Giả định từ NBD (Negative Binomial)

1. Khách hàng hoạt động với tần suất λ (lambda):

- Khi còn "alive", khách hàng giao dịch theo **Poisson process** với rate λ
- λ khác nhau giữa các khách hàng → Mô hình bằng **Gamma distribution**: $\lambda \sim \text{Gamma}(r, \alpha)$
- Mỗi khách hàng có λ riêng (heterogeneity trong transaction rate)
- **Kết quả:** Số giao dịch khi còn "alive" tuân theo **Negative Binomial Distribution**

Tại sao Negative Binomial?

- $\text{Poisson}(\lambda)$ với $\lambda \sim \text{Gamma}(r, \alpha)$ → Negative Binomial
- Negative Binomial mô hình được sự khác biệt về tần suất giữa các khách hàng
- Phù hợp với dữ liệu thực tế: đa số khách hàng giao dịch ít, một số ít giao dịch rất nhiều

2.3.3. Giả định từ BG (Beta Geometric)

2. Sau mỗi giao dịch, khách hàng có thể churn:

- Xác suất churn sau mỗi giao dịch: p
- p khác nhau giữa các khách hàng → Mô hình bằng **Beta distribution**: $p \sim \text{Beta}(a, b)$
- Mỗi khách hàng có p riêng (heterogeneity trong churn probability)
- **Kết quả**: Số giao dịch trước khi churn tuân theo **Geometric Distribution** với p từ Beta

Tại sao Geometric?

- Geometric distribution mô hình số lần thử (giao dịch) trước khi thành công (churn)
- Phù hợp với giả định: sau mỗi giao dịch có xác suất p để churn
- Beta-Geometric: p khác nhau giữa khách hàng → mô hình được heterogeneity

2.3.4. Giả định kết hợp

3. Khách hàng "dead" không còn giao dịch

- Một khi đã churn, khách hàng không bao giờ giao dịch nữa
- Đây là giả định quan trọng để phân biệt "alive nhưng ít giao dịch" vs "đã churn"

4. λ và p độc lập giữa các khách hàng

- Tần suất giao dịch (λ) và xác suất churn (p) là độc lập
- Một khách hàng có thể có λ cao (giao dịch nhiều) nhưng p cũng cao (dễ churn)
- Hoặc λ thấp (giao dịch ít) nhưng p thấp (ít churn)

Tóm tắt vai trò:

Thành phần	Vai trò	Mô hình hóa	Phân phối
NBD	Tần suất giao dịch	Sự khác biệt về transaction rate	Negative Binomial
BG	Quá trình churn	Sự khác biệt về churn probability	Beta-Geometric
Kết hợp	Dự đoán chính xác	Cả tần suất và churn	BG-NBD

2.3.1. Công thức phân phối: Gamma và Beta

2.3.1.1. Công thức Gamma Distribution

Gamma Distribution được sử dụng để mô hình hóa transaction rate λ :

Probability Density Function (PDF):

$$f(\lambda \mid r, \alpha) = \frac{\alpha^r}{\Gamma(r)} \lambda^{r-1} e^{-\alpha \lambda}, \quad \lambda > 0$$

Trong đó:

- λ : Transaction rate (biến ngẫu nhiên)
- $r > 0$: Shape parameter (tham số hình dạng)
- $\alpha > 0$: Rate parameter (tham số tỷ lệ)
- $\Gamma(r)$: Gamma function = $\int_0^{\infty} t^{r-1} e^{-t} dt$

Cumulative Distribution Function (CDF):

$$F(\lambda \mid r, \alpha) = \frac{\gamma(r, \alpha \lambda)}{\Gamma(r)}$$

Trong đó $\gamma(r, \alpha \lambda)$ là lower incomplete gamma function.

Mean và Variance:

$$E[\lambda] = \frac{r}{\alpha}$$

$$\text{Var}(\lambda) = \frac{r}{\alpha^2}$$

Mode (giá trị có xác suất cao nhất):

$$\text{Mode}(\lambda) = \frac{r-1}{\alpha}, \quad \text{nếu } r \geq 1$$

Tính chất:

- **Support:** $\lambda \in (0, \infty)$ → Phù hợp với transaction rate (luôn dương)
- **Shape:**
 - $r < 1$: Lệch phải mạnh, giảm dần từ 0
 - $r = 1$: Exponential distribution
 - $r > 1$: Có peak, lệch phải
 - $r \rightarrow \infty$: Tiến về Normal distribution
- **Rate parameter α :**
 - α lớn → Phân phối tập trung về 0 (nhiều khách hàng có λ thấp)
 - α nhỏ → Phân phối rải rộng hơn (nhiều khách hàng có λ cao)

Ký hiệu: $\lambda \sim \text{Gamma}(r, \alpha)$

2.3.1.2. Công thức Beta Distribution

Beta Distribution được sử dụng để mô hình hóa churn probability p :

Probability Density Function (PDF):

$$f(p \mid a, b) = \frac{p^{a-1}(1-p)^{b-1}}{B(a, b)}, \quad 0 \leq p \leq 1$$

Trong đó:

- p : Churn probability (biến ngẫu nhiên)
- $a > 0$: Shape parameter 1
- $b > 0$: Shape parameter 2
- $B(a, b)$: Beta function = $\frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)} = \int_0^1 t^{a-1}(1-t)^{b-1} dt$

Cumulative Distribution Function (CDF):

$$F(p \mid a, b) = \frac{B(p; a, b)}{B(a, b)} = I_p(a, b)$$

Trong đó $I_p(a, b)$ là regularized incomplete beta function.

Mean và Variance:

$$E[p] = \frac{a}{a + b}$$

$$\text{Var}(p) = \frac{ab}{(a+b)^2(a+b+1)}$$

Mode (giá trị có xác suất cao nhất):

$$\text{Mode}(p) = \frac{a-1}{a+b-2}, \quad \text{nếu } a > 1, b > 1$$

Tính chất:

- **Support:** $p \in [0, 1]$ → Phù hợp với xác suất
- **Shape:**
 - $a = b = 1$: Uniform distribution trên $[0, 1]$
 - $a = b$: Phân phối đối xứng, mode tại $p = 0.5$
 - $a > b$: Lệch trái (nhiều khách hàng có p thấp, ít churn)
 - $a < b$: Lệch phải (nhiều khách hàng có p cao, dễ churn)
- **Interpretation:**
 - a : "Số lần thành công" (không churn)
 - b : "Số lần thất bại" (churn)
 - $a + b$: "Tổng số lần thử" (tổng số giao dịch)

Ký hiệu: $p \sim \text{Beta}(a, b)$

2.3.1.3. Hình dạng phân phối

Gamma Distribution (cho λ):

- Hình dạng: Lệch phải (right-skewed), bắt đầu từ 0
- Tham số r (shape): Càng lớn, phân phối càng đối xứng hơn
- Tham số α (rate): Càng lớn, phân phối càng tập trung về 0
- Ứng dụng: Mô hình hóa tần suất giao dịch (luôn ≥ 0)

Beta Distribution (cho p):

- Hình dạng: Phân phối trên khoảng $[0, 1]$
- Tham số a, b :
 - $a = b$: Phân phối đối xứng
 - $a > b$: Lệch trái (nhiều khách hàng có p thấp)
 - $a < b$: Lệch phải (nhiều khách hàng có p cao)
- Ứng dụng: Mô hình hóa xác suất churn (luôn trong $[0, 1]$)

Code để visualize phân phối:

```

import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import gamma, beta

# Tạo figure với 2 subplots
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# ===== Gamma Distribution (cho  $\lambda$ ) =====
x_gamma = np.linspace(0, 10, 1000)
for r, alpha in [(1, 1), (2, 1), (3, 1), (2, 2)]:
    # scipy.stats.gamma dùng scale = 1/rate
    axes[0].plot(x_gamma, gamma.pdf(x_gamma, a=r, scale=1/alpha),
                 label=f'r={r},  $\alpha$ ={alpha}', linewidth=2)
axes[0].set_xlabel(' $\lambda$  (Transaction Rate)', fontsize=12)
axes[0].set_ylabel('Probability Density', fontsize=12)
axes[0].set_title('Gamma Distribution (for  $\lambda$  - Transaction Rate)', fontsize=14,
                  fontweight='bold')
axes[0].legend(fontsize=10)
axes[0].grid(True, alpha=0.3)
axes[0].set_xlim(0, 10)

# ===== Beta Distribution (cho p) =====
x_beta = np.linspace(0, 1, 1000)
for a, b in [(1, 1), (2, 2), (2, 5), (5, 2)]:
    axes[1].plot(x_beta, beta.pdf(x_beta, a, b),
                 label=f'a={a}, b={b}', linewidth=2)
axes[1].set_xlabel('p (Churn Probability)', fontsize=12)
axes[1].set_ylabel('Probability Density', fontsize=12)
axes[1].set_title('Beta Distribution (for p - Churn Probability)', fontsize=14,
                  fontweight='bold')
axes[1].legend(fontsize=10)
axes[1].grid(True, alpha=0.3)
axes[1].set_xlim(0, 1)

plt.tight_layout()
plt.savefig('bg_nbd_distributions.png', dpi=300, bbox_inches='tight')
plt.show()

```

Giải thích hình ảnh:

Gamma Distribution (trái):

- Mô tả phân bố tần suất giao dịch λ giữa các khách hàng
- Khách hàng có λ cao $\rightarrow$ giao dịch thường xuyên hơn
- Phân phối lệch phải $\rightarrow$ đa số khách hàng có tần suất thấp, một số ít có tần suất rất cao

Beta Distribution (phải):

- Mô tả phân bố xác suất churn p giữa các khách hàng
- Khách hàng có p cao $\rightarrow$ dễ churn hơn

- Phân phối trên $[0,1]$ → phù hợp với xác suất

2.3.1.4. Ví dụ tính toán

Ví dụ 1: Gamma Distribution

Giả sử $\lambda \sim \text{Gamma}(r=2, \alpha=1)$:

- Mean: $E[\lambda] = \frac{2}{1} = 2$ (transaction rate trung bình = 2 giao dịch/tháng)
- Variance: $\text{Var}(\lambda) = \frac{2}{1^2} = 2$
- Mode: $\text{Mode}(\lambda) = \frac{2-1}{1} = 1$

Ví dụ 2: Beta Distribution

Giả sử $p \sim \text{Beta}(a=2, b=5)$:

- Mean: $E[p] = \frac{2}{2+5} = \frac{2}{7} \approx 0.286$ (xác suất churn trung bình = 28.6%)
- Variance: $\text{Var}(p) = \frac{2 \times 5}{(2+5)^2(2+5+1)} = \frac{10}{392} \approx 0.0255$
- Mode: $\text{Mode}(p) = \frac{2-1}{2+5-2} = \frac{1}{5} = 0.2$ (giá trị có xác suất cao nhất = 20%)

Code tính toán:

```
import numpy as np
from scipy.stats import gamma, beta

# Gamma Distribution
r, alpha = 2, 1
lambda_dist = gamma(a=r, scale=1/alpha)
print(f"Gamma({r}, {alpha}):")
print(f"  Mean: {lambda_dist.mean():.2f}")
print(f"  Variance: {lambda_dist.var():.2f}")
print(f"  Mode: {(r-1)/alpha:.2f}")

# Beta Distribution
a, b = 2, 5
p_dist = beta(a=a, b=b)
print(f"\nBeta({a}, {b}):")
print(f"  Mean: {p_dist.mean():.4f}")
print(f"  Variance: {p_dist.var():.4f}")
print(f"  Mode: {(a-1)/(a+b-2):.4f}")
```

2.4. Tham số của BG-NBD

- **r, α**: Tham số của Gamma distribution cho λ
- **a, b**: Tham số của Beta distribution cho p

2.5. Input của BG-NBD

Với mỗi khách hàng, cần:

- **x**: Số lần giao dịch trong khoảng thời gian quan sát
- **tx**: Khoảng thời gian từ lần giao dịch đầu đến lần cuối
- **T**: Tổng thời gian quan sát (từ lần giao dịch đầu đến hiện tại)

2.6. Output của BG-NBD

- **P(alive)**: Xác suất khách hàng còn "alive"
- **E[transactions]**: Số giao dịch dự kiến trong tương lai

2.7. Công thức BG-NBD

2.7.1. Xác suất khách hàng còn alive

$$P(\text{alive} \mid r, \alpha, a, b, x, t_x, T) = \frac{1}{1 + \frac{a}{b+x-1}} \cdot \left(\frac{\alpha + T}{\alpha + t_x} \right)^{r+x}$$

Trong đó:

- r, α : Tham số Gamma distribution cho λ
- a, b : Tham số Beta distribution cho p
- x : Số lần giao dịch trong quá khứ
- t_x : Khoảng thời gian từ lần giao dịch đầu đến lần cuối
- T : Tổng thời gian quan sát

2.7.2. Số giao dịch dự kiến trong tương lai

$$E[\text{transactions trong } t \text{ periods tới}] = P(\text{alive}) \times \frac{r+x}{\alpha+T} \times t$$

Trong đó:

- $P(\text{alive})$: Xác suất khách hàng còn "alive" (từ công thức trên)
- t : Số periods (ngày/tháng) trong tương lai cần dự đoán

2.8. Ví dụ minh họa: Tại sao cần cả NBD và BG?

Tình huống: Có 2 khách hàng đều không giao dịch trong 60 ngày qua.

Khách hàng A:

- Trước đó: 10 giao dịch trong 6 tháng đầu
- Sau đó: 0 giao dịch trong 2 tháng gần đây
- **Câu hỏi:** Đã churn hay chỉ tạm thời không giao dịch?

Khách hàng B:

- Trước đó: 2 giao dịch trong 6 tháng đầu
- Sau đó: 0 giao dịch trong 2 tháng gần đây
- **Câu hỏi:** Đã churn hay chỉ có tần suất giao dịch thấp?

Phân tích với BG-NBD:

Khách hàng A:

- **NBD**: Có 10 giao dịch trước đó → λ cao (giao dịch thường xuyên)
- **BG**: Không giao dịch 60 ngày → Có thể đã churn (vì trước đó giao dịch nhiều)
- **Kết luận**: $P(\text{alive})$ thấp → Có khả năng đã churn

Khách hàng B:

- **NBD**: Chỉ có 2 giao dịch trước đó → λ thấp (giao dịch ít)
- **BG**: Không giao dịch 60 ngày → Có thể chỉ là do λ thấp (chưa đến lúc giao dịch)
- **Kết luận**: $P(\text{alive})$ cao hơn → Có thể vẫn còn "alive", chỉ là tần suất thấp

→ **BG-NBD phân biệt được 2 trường hợp này!**

Nếu chỉ dùng NBD:

- Cả 2 khách hàng đều được giả định còn "alive"
- Không phân biệt được khách hàng A (có thể đã churn) vs B (có thể chỉ ít giao dịch)
- Dự đoán sẽ sai cho khách hàng A

2.8.1. Bảng so sánh NBD, BG, và BG-NBD

Tiêu chí	NBD Only	BG Only	BG-NBD (Kết hợp)
Mô hình hóa	Transaction rate	Churn process	Cả 2
Heterogeneity	Có (λ khác nhau)	Có (p khác nhau)	Có (cả λ và p)
Phân biệt "alive" vs "dead"	✗ Không	☑ Có	☑ Có
Dự đoán số giao dịch	☑ Có (nhưng sai nếu đã churn)	✗ Không	☑ Có (chính xác)
Dự đoán $P(\text{alive})$	✗ Không (luôn = 1)	☑ Có	☑ Có
Phù hợp với dữ liệu thực	⚠ Một phần	⚠ Một phần	☑ Tốt
Ứng dụng	Khi biết chắc tất cả còn alive	Khi chỉ quan tâm churn	Dự đoán CLV

Kết luận:

- **NBD**: Tốt cho mô hình hóa transaction rate, nhưng không xử lý được churn
- **BG**: Tốt cho mô hình hóa churn, nhưng không mô hình được transaction rate
- **BG-NBD**: Kết hợp ưu điểm của cả 2 → Phù hợp nhất cho dự đoán CLV

2.9. Ước lượng tham số

Sử dụng Maximum Likelihood Estimation (MLE) để ước lượng r , α , a , b từ dữ liệu.

Quy trình:

1. Tính likelihood function dựa trên dữ liệu quan sát (x, t_x, T)
2. Tìm các tham số α, a, b để maximize likelihood
3. Sử dụng optimization algorithms (như BFGS, L-BFGS-B)
4. Validate với holdout data

3. Gamma-Gamma Model

3.1. Tổng quan

Gamma-Gamma là mô hình để ước lượng giá trị giao dịch trung bình tương lai của khách hàng.

3.2. Giả định

1. **Giá trị giao dịch của khách hàng i :** Z_i
2. **Z_i tuân theo Gamma distribution:** $Z_i \sim \text{Gamma}(p, v)$
3. **Tham số p tuân theo Gamma distribution:** $p \sim \text{Gamma}(q, \gamma)$
4. **v cố định cho tất cả khách hàng**

Visualization của Gamma-Gamma Model:

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import gamma

# Tạo figure
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# ===== Gamma distribution cho  $Z_i$  (transaction value) =====
x_transaction = np.linspace(0, 2000, 1000)
# Ví dụ với các tham số khác nhau
for p, v in [(2, 0.01), (3, 0.01), (5, 0.01)]:
    # Gamma với shape=p, scale=1/v
    axes[0].plot(x_transaction, gamma.pdf(x_transaction, a=p, scale=1/v),
                 label=f'p={p}, v={v}', linewidth=2)
axes[0].set_xlabel('Transaction Value  $Z$ ', fontsize=12)
axes[0].set_ylabel('Probability Density', fontsize=12)
axes[0].set_title('Gamma Distribution for Transaction Value  $Z_i$ ',
                  fontsize=14, fontweight='bold')
axes[0].legend(fontsize=10)
axes[0].grid(True, alpha=0.3)
axes[0].set_xlim(0, 2000)

# ===== Gamma distribution cho parameter  $p$  =====
x_p = np.linspace(0, 10, 1000)
# Ví dụ với các tham số  $q$ ,  $\gamma$  khác nhau
for q, gamma_val in [(2, 1), (3, 1), (5, 1)]:
    axes[1].plot(x_p, gamma.pdf(x_p, a=q, scale=1/gamma_val),
                 label=f'q={q},  $\gamma$ ={gamma_val}', linewidth=2)
axes[1].set_xlabel('Parameter  $p$ ', fontsize=12)
```

```
axes[1].set_ylabel('Probability Density', fontsize=12)
axes[1].set_title('Gamma Distribution for Parameter p',
                  fontsize=14, fontweight='bold')
axes[1].legend(fontsize=10)
axes[1].grid(True, alpha=0.3)
axes[1].set_xlim(0, 10)

plt.tight_layout()
plt.savefig('gamma_gamma_distributions.png', dpi=300, bbox_inches='tight')
plt.show()
```

Giải thích:

- **Trái:** Phân phối giá trị giao dịch Z_i của từng khách hàng
- **Phải:** Phân phối tham số p giữa các khách hàng (hierarchical structure)
- Gamma-Gamma cho phép mô hình hóa sự khác biệt về giá trị giao dịch giữa các khách hàng

3.3. Input của Gamma-Gamma

Với mỗi khách hàng:

- **m_x :** Giá trị giao dịch trung bình trong quá khứ
- **x :** Số lần giao dịch

3.4. Output của Gamma-Gamma

- **$E[Z]$:** Giá trị giao dịch trung bình dự kiến trong tương lai

3.5. Công thức Gamma-Gamma

$$E[Z \mid q, \gamma, m_x, x] = \frac{\gamma + q \cdot m_x \cdot x}{\gamma + x}$$

Trong đó:

- Z : Giá trị giao dịch trung bình tương lai
- q, γ : Tham số của Gamma distribution
- m_x : Giá trị giao dịch trung bình trong quá khứ
- x : Số lần giao dịch trong quá khứ

3.6. Ước lượng tham số

Ước lượng q , γ , v từ dữ liệu bằng MLE.

4. Kết hợp BG-NBD và Gamma-Gamma để tính CLV

4.1. Công thức CLV

$$CLV = E[\text{transactions}] \times E[\text{average transaction value}]$$

Trong đó:

- $E[\text{transactions}]$: Số giao dịch dự kiến (từ BG-NBD)
- $E[\text{average transaction value}]$: Giá trị giao dịch trung bình dự kiến (từ Gamma-Gamma)

4.2. CLV trong khoảng thời gian t

$$CLV(t) = E[\text{transactions trong } t \text{ periods}] \times E[Z]$$

4.3. CLV với discount rate

$$CLV(t) = \sum_{i=1}^t \frac{E[\text{transactions trong period } i] \times E[Z]}{(1 + r)^i}$$

Trong đó:

- r : Discount rate (thường 0.1-0.15, tức 10-15% mỗi period)
- i : Thời kỳ (1, 2, 3, ..., t)
- $E[Z]$: Giá trị giao dịch trung bình dự kiến

4.4. Quy trình tính CLV

1. **Chuẩn bị dữ liệu**: Tính x, tx, T, mx cho mỗi khách hàng
2. **Fit BG-NBD**: Ước lượng r, α, a, b
3. **Fit Gamma-Gamma**: Ước lượng q, γ, v
4. **Tính P(alive)**: Từ BG-NBD
5. **Tính E[transactions]**: Từ BG-NBD
6. **Tính E[Z]**: Từ Gamma-Gamma
7. **Tính CLV**: $E[\text{transactions}] \times E[Z]$

5. Ứng dụng CLV trong Cross-sell, Up-sell, Ưu tiên khách hàng

5.1. Cross-sell

Mục tiêu: Giới thiệu sản phẩm mới cho khách hàng hiện tại

Chiến lược:

- Tập trung vào khách hàng có CLV cao
- Khách hàng có P(alive) cao
- Khách hàng đã sử dụng nhiều sản phẩm

5.2. Up-sell

Mục tiêu: Nâng cấp dịch vụ cho khách hàng

Chiến lược:

- Khách hàng có CLV cao nhưng chưa sử dụng dịch vụ premium
- Khách hàng có E[Z] cao (giá trị giao dịch lớn)
- Khách hàng có frequency cao

5.3. Ưu tiên khách hàng

5.3.1. Phân nhóm theo CLV

- **High CLV:** CLV > 75th percentile
- **Medium CLV:** 25th percentile < CLV < 75th percentile
- **Low CLV:** CLV < 25th percentile

5.3.2. Chiến lược

Nhóm	CLV	P(alive)	Chiến lược
Champions	High	High	VIP program, retention
Potential	Medium	High	Upsell, cross-sell
At Risk	High	Low	Win-back campaign
Low Value	Low	Low	Cost-effective service

5.4. Tối ưu ngân sách marketing

$$ROI = \frac{CLV \times \text{Conversion Rate}}{\text{Marketing Cost}}$$

Ưu tiên khách hàng có ROI cao nhất.

5.5. Customer Acquisition Cost (CAC) vs CLV

- **CAC:** Chi phí để có được khách hàng mới
- **CLV/CAC Ratio:**
 - 3: Tốt
 - 1-3: Cần cải thiện
 - < 1: Không bền vững

6. Ưu và nhược điểm của BG-NBD + Gamma-Gamma

6.1. Ưu điểm

- **Probabilistic:** Cung cấp xác suất, không chỉ điểm số
- **Interpretable:** Dễ hiểu và giải thích
- **Không cần nhiều features:** Chỉ cần transaction history
- **Handles churn:** Tự động xử lý khả năng churn
- **Proven:** Được sử dụng rộng rãi trong thực tế

6.2. Nhược điểm

- **Giả định phân phối:** Có thể không phù hợp với mọi loại dữ liệu
- **Không sử dụng features khác:** Chỉ dựa trên transaction history
- **Computational:** Cần optimize tham số
- **Assumes stationarity:** Giả định hành vi không đổi theo thời gian

7. Best Practices

1. **Chuẩn bị dữ liệu tốt:** Đảm bảo dữ liệu sạch và đầy đủ
2. **Chọn khoảng thời gian phù hợp:** Thường 6-12 tháng
3. **Validate mô hình:** So sánh dự đoán với thực tế
4. **Cập nhật định kỳ:** Retrain mô hình hàng quý
5. **Kết hợp với domain knowledge:** Hiểu rõ ngữ cảnh business
6. **Monitor performance:** Theo dõi accuracy của dự đoán

8. Thư viện Python

- **lifetimes:** Thư viện chuyên dụng cho BG-NBD và Gamma-Gamma
- **scipy:** Optimization và statistical functions
- **pandas, numpy:** Data manipulation